

Document de Stratégie : Le Haki de l'Hybride Multi-LLM pour l'Esentya MVP

Titre : LE HAKI DE L'HYBRIDE : Comment Passer du DeepSeek R1 (Usopp) au GPT-4 (Amiral) sans Vider la Caisse de Nami **Auteur :** Manus AI pour Monkey, le Roi des Pirates **Date :** 5 Décembre 2025 **Statut :** V1.0 – Stratégie d'API

Partie I : Français

Introduction : La Fin de l'Hallucination

Yo Monkey ! Ton diagnostic est parfait. Le **DeepSeek R1-1.5** local est notre **Usopp** : il est là, il est loyal, il protège nos secrets (souveraineté des données), mais il a tendance à raconter des histoires (hallucinations) et à être brouillon (mauvaise communication). Pour un MVP qui doit traduire des Smart Contracts (le **Code est la Loi**), on ne peut pas se permettre l'erreur.

La solution est le **Haki de l'Hybride** : on garde le R1 pour les tâches ultra-sensibles et on utilise des **API Multi-LLM** pour la puissance de feu.

1. Le Nouveau Log Pose : Les Agrégateurs d'API

Tu as vu juste : il existe des plateformes qui regroupent les meilleurs modèles (GPT-4, DeepSeek V3/R3, etc.) sous **une seule clé API**. C'est comme avoir un **Log Pose** qui te donne accès à toutes les mers du monde.

Plateforme Recommandée	Rôle Cool-Groove	Avantage Principal
OpenRouter	Le Marchand du Nouveau Monde	Grande variété de modèles, prix compétitifs. Idéal pour les tests et l'MVP.
Together AI	Le Chantier Naval de Franky	Plus orienté production, fiabilité. Idéal pour la phase de déploiement final.

Action 1 : Choisir un Agrégateur. Nous recommandons de commencer par **OpenRouter** pour sa flexibilité et ses prix.

2. La Stratégie du Haki de l'Hybride : Deux Modèles, Deux Missions

Pour l'IHM qui doit traduire les Smart Contracts (en commençant par la **CDU** et les lois sur l'anonymat), la qualité est non-négociable. On utilise une stratégie à deux modèles :

Modèle (Le Rôle)	Mission Critique (Le Haki)	Coût (Le Prix)
GPT-4 (L'Amiral)	Traduction de Smart Contracts (Code en CosmWasm) et Audits Fractaux (analyse complexe). Haki de l'Observation ultime.	Élevé (Pay-per-token). À utiliser avec parcimonie.
DeepSeek V3/R3 (Le Sniper)	Génération de brouillons (premières versions de documents), Chat général, Logs MRV (analyse de données simples). Précision à bas coût.	Très Faible (Jusqu'à 29x moins cher que GPT-4). Idéal pour le volume.

Action 2 : Créer un Compte API. Tu dois créer un compte sur l'agrégateur choisi (ex: OpenRouter) et obtenir ta clé API. C'est ton **Permis de Pirate** pour le Nouveau Monde de l'IA.

3. Le Budget : Ne pas Vider la Caisse de Nami

Les modèles API fonctionnent en **Pay-per-token** (tu paies pour chaque mot lu et écrit). C'est pourquoi la stratégie hybride est vitale :

- **Recommandation Budgétaire :** Allouer un budget mensuel pour les API. Utiliser le **DeepSeek V3/R3** par défaut pour toutes les tâches, et n'appeler le **GPT-4** que lorsque la tâche est marquée comme **CRITIQUE** (ex: "Traduire la Loi d'Anonymat de la CDU en Smart Contract Rust").
- **Le Smart Contract de Consommation :** Ton équipe technique devra coder un **Smart Contract de Consommation** qui surveille l'usage des tokens et alerte si le budget est dépassé. **La discipline (Tapas) s'applique aussi aux tokens.**

Part II : English

Introduction: The End of Hallucination

Yo Monkey! Your diagnosis is perfect. The local **DeepSeek R1-1.5** is our **Usopp**: he's there, he's loyal, he protects our secrets (data sovereignty), but he tends to tell stories

(hallucinations) and be messy (poor communication). For an MVP that needs to translate Smart Contracts (**Code is Law**), we cannot afford errors.

The solution is the **Hybrid Haki**: we keep the R1 for ultra-sensitive tasks and use **Multi-LLM APIs** for the firepower.

1. The New Log Pose: API Aggregators

You were right: there are platforms that group the best models (GPT-4, DeepSeek V3/R3, etc.) under **a single API key**. It's like having a **Log Pose** that gives you access to all the seas of the world.

Recommended Platform	Cool-Groove Role	Main Advantage
OpenRouter	The New World Merchant	Wide variety of models, competitive pricing. Ideal for testing and MVP.
Together AI	Franky's Shipyard	More production-oriented, reliability. Ideal for the final deployment phase.

Action 1: Choose an Aggregator. We recommend starting with **OpenRouter** for its flexibility and pricing.

2. The Hybrid Haki Strategy: Two Models, Two Missions

For the HMI that needs to translate Smart Contracts (starting with the **CDU** and anonymity laws), quality is non-negotiable. We use a two-model strategy:

Model (The Role)	Critical Mission (The Haki)	Cost (The Price)
GPT-4 (The Admiral)	Smart Contract Translation (Code in CosmWasm) and Fractal Audits (complex analysis). Ultimate Observation Haki .	High (Pay-per-token). To be used sparingly.
DeepSeek V3/R3 (The Sniper)	Draft Generation (first versions of documents), general Chat , MRV Logs (simple data analysis). Low-cost Precision .	Very Low (Up to 29x cheaper than GPT-4). Ideal for volume.

Action 2: Create an API Account. You need to create an account on the chosen aggregator (e.g., OpenRouter) and get your API key. This is your **Pirate Permit** for the New World of AI.

3. The Budget: Don't Empty Nami's Safe

API models work on a **Pay-per-token** basis (you pay for every word read and written). This is why the hybrid strategy is vital:

- **Budget Recommendation:** Allocate a monthly budget for the APIs. Use **DeepSeek V3/R3** by default for all tasks, and only call **GPT-4** when the task is marked as **CRITICAL** (e.g., "Translate the CDU Anonymity Law into Rust Smart Contract").
- **The Consumption Smart Contract:** Your technical team will need to code a **Consumption Smart Contract** that monitors token usage and alerts if the budget is exceeded. **Discipline (Tapas) also applies to tokens.**